

Universidad del Valle de Guatemala

CC3084 · Data Science · Sección 10

Laboratorio 6

Analítica de Redes Sociales

Participación, comunidades, puentes y sentimiento en YouTube

Jorge Gabriel Palacios Sales	231385
Pablo Daniel Barillas Moreno	22193
Roberto Emiliano Otoniel	23968

Grupo 1 · Segundo semestre 2026

Entrega final reproducible

Contenido

1	Resumen ejecutivo	1
2	Datos, calidad y preprocesamiento	1
3	Análisis exploratorio	2
4	Construcción de redes	4
4.1	Red bipartita autor–video	4
4.2	Proyecciones	4
5	Topología y fragmentación	6
6	Comunidades	6
7	Centralidad, puentes y articuladores	8
8	Contenido y sentimiento	9
9	Respuestas integradas	10
10	Limitaciones y ética	11
11	Conclusiones	11
12	Reproducibilidad y trazabilidad	11

1 Resumen ejecutivo

Se analizaron 293 videos y 406 comentarios asociados a 332 autores y 97 canales. La integración comentario–video fue de 100%, pero la cobertura de comentarios alcanza solo 19 videos; esta asimetría se conserva y discute como limitación. La red bipartita contiene 625 nodos y 343 aristas únicas autor–video. Sus proyecciones revelan una participación fuertemente localizada: nueve autores comentaron en más de un video, solo diez videos comparten audiencia y 283 videos quedan aislados.

El análisis estructural identifica siete autores puente y cinco videos articuladores. La remoción de 12 de 25 candidatos incrementa la fragmentación. Louvain ponderado detecta diez comunidades, con modularidad 0.395. El análisis de sentimiento con RoBERTuito clasifica 61.3% de comentarios como negativos, 18.5% neutrales y 20.2% positivos, con confianza media de 0.818. Estos resultados caracterizan el corpus entregado y no deben generalizarse a todos los usuarios de YouTube.

Videos	293	Comentarios	406
Canales	97	Autores	332
Videos con comentarios	19	Integración	100%
Comunidades	10	Modularidad	0.395
Autores puente	7	Videos articuladores	5

Tabla 1: Indicadores principales de la entrega final.

2 Datos, calidad y preprocesamiento

Los insumos oficiales son `youtube_videos.csv` y `youtube_comments.csv`. El cargador inspecciona el contenido y admite CSV real, XLSX real o un libro Excel con extensión incorrecta. Se normalizaron tipos, espacios, conteos e identificadores; no fue necesario reconstruir `video_id`. Se conservaron el texto original y una versión limpia: la segunda se usa para frecuencias, mientras la primera alimenta sentimiento para preservar negación, emojis y puntuación.

En videos, cada fila representa un video y `video_id` es llave primaria. En comentarios, cada fila representa un comentario principal y `comment_id` es llave primaria; `video_id` es la llave foránea. `channel_id` identifica al canal propietario, mientras `author_channel_id` identifica al autor. La categoría pertenece al video y `source_query` documenta la consulta de recolección, no necesariamente el tema definitivo. El diagnóstico incluye dimensiones, tipos, faltantes, duplicados, constantes, atípicos por IQR y consistencia de IDs, nombres y handles.

- Los IDs, no los nombres visibles, definen los nodos.
- Los videos sin comentarios se conservan como aislados.
- `viewer_rating` se excluye por ausencia total; `is_pinned` se mantiene solo para auditoría por ser constante.
- `reply_count` es descriptivo: no contiene autor ni texto de cada respuesta y, por tanto, no genera aristas.
- Los conteos de texto admiten comas, espacios y sufijos K, mil, M, millón/millones; los vacíos descriptivos se convierten a cero y los valores inválidos, a faltante.
- La integración valida una relación muchos-a-uno entre comentarios y videos.




Figura 1: Panorama exploratorio de videos y comentarios.

3 Análisis exploratorio

Se calcularon participaciones por video, canal y autor, concentración acumulada, distribución temática y asociación entre visibilidad y comentarios. Los cinco videos con mayor actividad reúnen 75.4% de los comentarios. En los 293 videos, vistas y comentarios tienen asociación débil (Spearman $\rho = 0.080$, $p = 0.170$); entre los 19 videos con comentarios, $\rho = 0.811$ ($p < 0.001$). La diferencia es efecto de cobertura/selección, no evidencia causal.




Figura 2: Términos, bigramas y hashtags frecuentes después de la limpieza.




Figura 3: Relación descriptiva entre vistas y participación observada.

Hallazgo. La concentración de comentarios no demuestra centralidad estructural. Un video con muchos comentarios puede formar una camarilla grande y, aun así, no conectar audiencias distintas.

4 Construcción de redes

4.1 Red bipartita autor–video

Cada autor y cada video es un nodo de distinto tipo. Existe una arista si el autor comentó el video; su peso conserva la cantidad de comentarios de esa pareja. La red tiene 625 nodos y 343 aristas únicas. Esta definición expresa participación observable, no amistad, aprobación ni coordinación.





Figura 4: Red bipartita completa; los aislados se conservan para representar la cobertura real.

4.2 Proyecciones

En la proyección autor–autor, dos autores se conectan al comentar un mismo video. En la proyección video–video, dos videos se conectan si comparten al menos un autor. Los pesos cuentan videos o autores compartidos, respectivamente. La primera red contiene 332 nodos y 10,732 aristas; la segunda, 293 nodos y 11 aristas.


Proyección autor-autor



Nodos aislados conservados en tablas/métricas: 4

Figura 5: Proyección de coparticipación entre autores.

Proyección video-video



Nodos aislados conservados en tablas/métricas: 283

Figura 6: Proyección entre videos con audiencia compartida.

5 Topología y fragmentación

Se reportaron componentes, densidad, grados, periferia y tamaño de la componente mayor. La proyección de videos contiene una sola componente de diez videos conectados y 283 aislados. La proyección de autores presenta transitividad 0.984, agrupamiento ponderado 0.486 y conectividad de nodos/aristas 1/5 en su componente mayor; la de videos presenta transitividad 0.316, agrupamiento 0.006 y conectividad 1/1. La forma de las proyecciones surge de camarillas inducidas por cada video: hay redundancia dentro de ellas y pocos enlaces entre ellas.

Para comprobar qué nodos son indispensables, se retiraron candidatos elegidos por centralidad y articulación. De 25 nodos evaluados, 12 aumentan el número de componentes. El mayor incremento de fragmentación es 0.239 al remover a @virgiliogarcia3039.




Figura 7: Cambio estructural después de remover candidatos centrales.

6 Comunidades

Se seleccionó la proyección autor–autor porque representa patrones de coparticipación y permite asociar directamente el contenido escrito por los participantes. Louvain maximiza modularidad y usa como peso el número de videos compartidos; con semilla 42 produjo diez comunidades y modularidad 0.395. Cada grupo se caracterizó mediante tamaño, intensidad, aristas internas y externas, densidad, articuladores, términos, videos, canales, categorías y sentimiento. Cuatro autores aislados no reciben una comunidad artificial: para agregaciones se registran explícitamente como grupo 0, “sin comunidad”.

La comunidad 1 reúne 126 autores y 161 comentarios en tres videos/canales; predominan “pueblo”, “dinero” y “diputados”, con 80.7% negativo. La comunidad 2 incluye 61 autores y 83 comentarios alrededor de Gobierno/Noti7 y términos como “presidente”, “Guatemala” y “Arévalo”; presenta 44.6% negativo, 27.7% neutral y 27.7% positivo. La comunidad 3 contiene 55 autores y 60 comentarios principalmente sobre USAC/corrupción en Quorum y TN23; presenta 61.7% negativo. Las comunidades

2 y 3 dependen de pocos nodos articuladores, mientras que la 1 es internamente muy densa. Como contraste adicional, la comunidad 5 es 84.0% positiva (25 comentarios). Los grupos menores que cinco se muestran, pero no se interpretan formalmente.




Figura 8: Comunidades detectadas en la proyección autor–autor.




Figura 9: Distribución de sentimiento por comunidad; el grupo 0 contiene aislados.

7 Centralidad, puentes y articuladores

Se usaron medidas complementarias: grado y grado ponderado para alcance directo; intermediación para circulación entre regiones; cercanía armónica por la desconexión de la red; PageRank ponderado para relevancia de vecinos. La etiqueta de puente estructural exige intermediación positiva, condición de punto de articulación y un efecto medido al remover el nodo.

Siete autores cumplen la definición: @virgiliogarcia3039, @inge_vergueta, @josegil3813, @franciscoflores3120, @hashojea7348, @MarcosCarillo-b1r y @moisesvaldez4043. Dos autores adicionales presentan intermediación positiva, pero cuentan con rutas alternativas y se clasifican como puentes redundantes.

Cinco videos son articuladores: “Qué rico come tu diputado”, “Internet: escoger el menos malo”, “Conferencia de Prensa del Gobierno de Guatemala. #LaRondaGt”, “La cooptación de Walter Mazariegos en la USAC” e “Inician los trabajos de recuperación del Puente Belice II.”




Figura 10: Autores puente y evidencia estructural.




Figura 11: Videos que articulan audiencias compartidas.

Hallazgo. Recurrencia e intermediación no son equivalentes. Comentar varios videos permite tender puentes, pero la intermediación depende de qué regiones se conectan y de si existen rutas alternativas.

8 Contenido y sentimiento

Se empleó [pysentimiento/robertuito-sentiment-analysis](#), un clasificador NEG/NEU/POS basado en RoBERTuito para texto social en español. Se guardan probabilidades de las tres clases, etiqueta, confianza, margen, revisión del modelo, versión de `transformers` y huella SHA-256 del texto. La caché solo se reutiliza cuando coinciden modelo, IDs y textos; `LAB6_FORCE_SENTIMENT=1` fuerza una nueva inferencia.

Clase	Comentarios	Porcentaje
Negativo	249	61.3%
Neutral	75	18.5%
Positivo	82	20.2%

Tabla 2: Distribución general de sentimiento en los 406 comentarios.

La confianza media es 0.818. Hay 61 predicciones bajo 0.60 (15.0%), 89 entre 0.60 y 0.80 (21.9%) y 256 por encima de 0.80 (63.1%). Las comparaciones por video, canal, categoría y comunidad requieren al menos cinco comentarios para considerarse interpretables.




Figura 12: Distribución general y confianza de la clase ganadora.




Figura 13: Diagnóstico de confianza del modelo.

9 Respuestas integradas

1. **Concentración.** El video líder es “Qué rico come tu diputado” y el canal líder es Quorum; los cinco videos principales concentran 75.4%.
2. **Audiencias compartidas.** Existen, pero son escasas: nueve autores aparecen en más de un video y generan 11 conexiones video-video.
3. **Puentes.** Siete autores son articuladores reales según intermediación, corte y remoción.

4. **Comunidades.** Diez grupos combinan evidencia estructural y contenido; se documentan temas y sentimiento sin interpretar muestras menores que cinco.
5. **Articulación de videos.** Cinco videos separan segmentos de la componente compartida si se retiran.
6. **Remoción.** Doce de los 25 candidatos evaluados incrementan fragmentación.
7. **Sentimiento.** Predomina la clase negativa, pero 15.0% de predicciones tiene baja confianza y exige cautela.

10 Limitaciones y ética

- La cobertura de comentarios es parcial y no aleatoria: 19 de 293 videos.
- Las consultas y canales usados en recolección condicionan temas y comunidades observadas.
- Un canal de autor no equivale necesariamente a una persona; se evita intentar reidentificar usuarios.
- Los conteos de vistas, likes y respuestas constituyen una instantánea temporal.
- La copresencia no prueba interacción directa ni coordinación.
- Ironía, jerga, código mixto y contexto político limitan el clasificador de sentimiento.
- No se reproducen textos sensibles innecesariamente en el informe; los datos se usan con fin académico.

11 Conclusiones

La participación está concentrada, pero la conexión entre audiencias es excepcional. La mayoría de autores aparece en un solo video y casi todos los videos quedan aislados en la proyección. Los puentes identificados son valiosos no por comentar mucho, sino porque conectan camarillas que perderían continuidad al removerlos.

Las comunidades ofrecen una lectura más rica al integrar estructura, temas y sentimiento. El tono general es predominantemente negativo, aunque existe heterogeneidad importante, incluida una comunidad mayoritariamente positiva. La fuerza del análisis reside en triangular métricas y reconocer las limitaciones de cobertura; no en presentar la red o el modelo como una representación completa de YouTube Guatemala.

12 Reproducibilidad y trazabilidad

El pipeline completo se ejecuta con:

```
python -m pip install -r requirements.txt
python scripts/run_final.py
python scripts/build_final_notebook.py
cd reports
```

```
pdflatex -interaction=nonstopmode -halt-on-error informe_final.tex
pdflatex -interaction=nonstopmode -halt-on-error informe_final.tex
```

El repositorio contiene datos originales, código modular, notebook ejecutado, tablas, figuras, pruebas, fuente LaTeX y PDF. La tabla `cumplimiento_rubrica_final.csv` enlaza los nueve criterios de calificación con evidencia concreta, y `evidencia_ejercicios.csv` hace lo propio con los diez ejercicios.

Repositorio: [GitHub](#) · [Laboratorio 6](#) · [Grupo 1](#)

Referencias metodológicas

- Hagberg, A., Swart, P. y Schult, D. *Exploring network structure, dynamics, and function using NetworkX*.
- Blondel, V. et al. (2008). *Fast unfolding of communities in large networks*.
- Pérez, J. M. et al. RoBERTuito y [pysentimiento](#): análisis de sentimiento en español.